

EEL891 - Relatório 1: Classificação

UFRJ

Engenharia Eletrônica e de Computação

João Pedro Duarte Baptista

DRE: 121066907

Professor: Heraldo Luis Silveira de Almeida

27/11/2025

1 Objetivo da Regressão:

Identificar, dentre os clientes que solicitam um produto de crédito (como um cartão de crédito ou um empréstimo pessoal, por exemplo) e que cumprem os pré-requisitos essenciais para a aprovação do crédito, aqueles que apresentem alto risco de não conseguirem honrar o pagamento, tornando-se inadimplentes. A implementação do trabalho foi realizada com as ferramentas Jupyter Notebook e Google Colab.

2 Pré-Processamento dos Dados

Após analisar o conjunto de dados, algumas decisões foram tomadas para filtrar melhor os dados.

1) Primeiramente, algumas variáveis foram identificadas como redundantes ou de pouca importância, ou até mesmo houve a recomendação de ignorá-las pelo dicionário de dados. Portanto, elas foram descartadas no pré-processamento: 'possui-telefone-celular', 'codigo-area-telefone-trabalho', 'qtde-contas-bancarias-especiais', 'id-solicitante', 'codigo-area-telefone-residencial', 'grau-instrucao'.

2) Depois, algumas outras colunas tinham muitos valores nulos em suas linhas. Então, seus valores nulos foram substituídos por -1, já que eram atributos considerados importantes para a aprovação de crédito. Foi considerado que a ausência dessas informações significava que o requisitante não a tinha, mas não poderia ser atribuído o valor 0 pois o dicionário estipulava um significado para o valor 0, ou então a variável seria posteriormente transformada em dummies. Essas variáveis eram: profissao, ocupacao, profissao-companheiro e grau-instrucao-companheiro.

3) Em seguida, foi feita a substituição dos nomes dos estados de residência, trabalho e nascimento dos requisitantes por um valor correspondente à sua frequência relativa, ou seja, um estado qualquer teve seu valor alterado para uma porcentagem. Esse método tornou mais fácil de estipular um valor para cada estado existente na lista. Os valores nulos e XX que apareciam no conjunto de dados foram substituídos por n-informado, que também teve a si um valor atribuído.

4) Colunas numéricas com valores sem significado tiveram seus valores alterados para string, para depois serem alteradas para dummies. Por exemplo, as profissões eram numeradas de 0 a 18, então foram criadas colunas de profissao-1, profissao-2, e assim por diante.

5) Linhas vazias de colunas numéricas tiveram seus valores alterados pela mediana da respectiva categoria, ao invés de usar a média, que poderia ser muito influenciada por outliers. Nesse caso, as variáveis são: idade, meses-na-residencia, meses-no-trabalho, renda-mensal-regular, renda-extra e valor-patrimonio-pessoal.

6) Variáveis binárias textuais, as quais tinham informações descritas como Y e N (sim e não), tiveram seus valores alterados para 1 e 0, assumindo que valores vazios equivalem a 0. Elas eram: possui-telefone-residencial, vinculo-formal-com-empresa e possui-telefone-trabalho.

7) As demais colunas foram tratadas para terem suas linhas vazias preenchidas por 'N'. Em seguida, foram tratadas para serem separadas em dummies, resultando em um total de 93 categorias.

3 Encoding

Foram utilizados quatro métodos de Encoding ao longo do trabalho, como introduzido na seção de Pré-Processamento.

1) Frequency Encoding Usado nas variáveis de estados para evitar gerar 81 colunas novas (27 estados em 3 categorias diferentes). Esse tipo de codificação manteve apenas as 3 colunas já existentes, substituindo os valores textuais por valores percentuais.

2) One-Hot Encoding (dummies) Usado na maioria das categorias, criando uma coluna binária para cada opção possível (sexo-M, sexo-F, profissao-1, profissao-18, etc). Esses dados não eram ordenados nem tinham valores com significados explicitamente mais importantes que outros.

3) Mapeamento Binário Usado nas colunas binárias de Y e N, traduzindo Y em 1 e N em 0, para ser utilizado no modelo matemático sem alterar o número de colunas.

4) Ordinal Encoding Usado nas colunas cujos valores numéricos possuíam significados explícitos (grau-instrucao e qtde-dependentes), enumerados por 0, 1, 2, ...; Como existia uma hierarquia evidente, ou seja, o valor 5 era melhor que o valor 1, essa abordagem simplifica e melhora o resultado.

4 Modelo

Foram utilizados e comparados três modelos de classificação. O primeiro modelo foi o Random Forest Classifier (RF), que gerou os piores resultados e, portanto, foi descartado. Depois, foi utilizado o Gradient Boosting Classifier (GB), que obteve resultados ligeiramente mais acurados, tendo métricas de ROC-AUC e Recall mais elevadas. Entretanto, o resultado ainda não estava satisfatório e, por isso, a abordagem foi mudada novamente, para utilizar o XGBoost Classifier (XGB - Extreme Gradient Boosting).

Esse modelo superou os dois anteriores nas métricas e permitiu o uso de hiperparâmetros diferentes (parâmetros L1 e L2), com o intuito de evitar overfitting. Esse modelo também permitiu o descarte de variáveis irrelevantes, que tiveram o grau de importância calculado como abaixo de 0.001.


Com esse modelo, também foi possível otimizar o algoritmo de classificação, interrompendo o processo assim que o desempenho começasse a decair, economizando tempo e memória do sistema.

Após descartar as variáveis menos importantes, foi realizada uma modelagem otimizada, considerando apenas 52 das 93 colunas originais, tornando o modelo menos custoso computacionalmente e mais eficiente, chegando à Matriz de Confusão XGB.

Depois, foi possível calcular o threshold de risco para a aprovação do crédito dos requisitantes. Ou seja, ao invés de recusar o crédito caso o risco fosse maior que 50%, o crédito seria recusado caso o risco fosse maior que 46.32%, reduzindo a quantidade de diagnósticos de falsos-positivos, o que reduziria o prejuízo do banco. Isso nos gerou uma nova matriz de confusão, com índices de Recall de aproximadamente 73.6%, muito superiores aos anteriores de 63% e 60.4%.

5 Resultados


Foi calculada a importância relativa de cada variável para o resultado final.




Variaveis menos importantes


	Variavel	Importancia
24	profissao_15.0	0.0
19	profissao_10.0	0.0
13	meses_no_trabalho	0.0
23	profissao_14.0	0.0
18	profissao_1.0	0.0
50	profissao_companheiro_2.0	0.0
53	profissao_companheiro_8.0	0.0
42	profissao_companheiro_1.0	0.0
45	profissao_companheiro_12.0	0.0
28	profissao_3.0	0.0
25	profissao_16.0	0.0
26	profissao_17.0	0.0
29	profissao_4.0	0.0
38	ocupacao_3.0	0.0
30	profissao_5.0	0.0
31	profissao_6.0	0.0
51	profissao_companheiro_3.0	0.0
52	profissao_companheiro_6.0	0.0
49	profissao_companheiro_17.0	0.0
46	profissao_companheiro_13.0	0.0
47	profissao_companheiro_14.0	0.0
48	profissao_companheiro_16.0	0.0
43	profissao_companheiro_10.0	0.0
62	tipo_endereco_2	0.0
71	nacionalidade_2	0.0
76	tipo_residencia_3.0	0.0
77	tipo_residencia_4.0	0.0
82	sexo_N	0.0
86	possui_cartao_diners_1	0.0
87	possui outros cartoes 1	0.0

Também foi calculada a matriz de confusão dos modelos GB e XGB.





Com essas matrizes, é possível ver que os resultados dos dois modelos foram próximos e seus respectivos scores no kaggle eram também muito próximos, com variações de milésimos entre eles. O quadrado inferior esquerdo representa a maior margem de prejuízo. Então, quanto menor for o valor, melhor para o banco que utiliza o modelo. Entretanto, a quantidade de positivos verdadeiros também foi reduzida, significando que o crédito seria negado para mais clientes em condições de pagar em dia. Por isso, o resultado entregue com maior escore foi o resultante do modelo GB.



Na imagem abaixo, é possível ver a curva ROC do modelo utilizado. A linha tracejada representa um modelo que simplesmente tenta adivinhar o resultado da classificação, como em um jogo de cara ou coroa. A linha laranja representa o modelo produzido no trabalho, levemente curvado para o canto superior esquerdo, confirmando que ele é melhor do que o acaso. O AUC encontrado foi de 64.25%, ou seja, a capacidade de distinguir os bons pagadores dos inadimplentes é relativamente boa.

O ponto preto marcado sobre a linha laranja representa o threshold dito anteriormente, de 46.32%, sendo o ponto de corte de melhor eficiência para o modelo.

A curva suave e sem degraus indica que o modelo não sofre de overfitting.

