

EEL891 - Relatório 2: Regressão

UFRJ

Engenharia Eletrônica e de Computação

João Pedro Duarte Baptista

DRE: 121066907

Professor: Heraldo Luis Silveira de Almeida

20/11/2025

1 Objetivo da Regressão:

Estimar o preço de um imóvel a partir de características tais como o tipo de imóvel (apartamento, casa, loft ou quitinete), bairro onde está localizado, número de quartos, número de vagas, área útil, área extra e presença de elementos diferenciais em relação a outros imóveis, tais como churrasqueira, estacionamento para visitantes, piscina, playground, quadra esportiva, campo de futebol, salão de festas, salão de jogos, sala de ginástica, sauna e vista para o mar.

A implementação do trabalho foi realizada com as ferramentas Jupyter Notebook e Google Colab.

2 Pré-Processamento dos Dados

Após analisar o conjunto de dados, algumas decisões foram tomadas para filtrar melhor os dados.

1) Em primeiro lugar, entende-se que uma suíte é, obrigatoriamente, um quarto. Portanto, a quantidade de quartos foi destrinchada em quartos simples e suítes, para que a quantidade de suítes não influenciasse duas vezes no valor do imóvel.

2) Depois, os itens diferenciais (churrasqueira, estacionamento, piscina, playground, quadra, salão de festas, salão de jogos, sala de ginástica e sauna) foram categorizados como itens de lazer, sendo somados e substituídos por uma coluna de score de lazer, a fim de reduzir a complexidade da solução e evitar a atribuição arbitrária de valores para cada uma dessas colunas.

3) Em seguida, foi feita a diferenciação dos tipos de imóvel (casa, apartamento, quitenete e loft) e a diferenciação dos tipos de vendedor (imobiliária ou pessoa física), também a fim de simplificar a solução e reduzir a dimensionalidade.

4) Foi feita a limpeza de outliers no conjunto de dados. Ou seja, imóveis com área útil menor que 10m^2 foram excluídos. Também foram excluídos imóveis com preços menores que 10.000 reais e maiores que 4.100.000 reais, para aumentar a confiabilidade do modelo.

5) Por último, cada bairro foi separado em um valor de acordo com a média do preço do metro quadrado útil. Também foi testado usar a mediana no lugar da média, mas o resultado obtido foi pior.

3 Encoding

O método de Encoding utilizado foi, principalmente, Target Encoding, que foi usado para calcular a média de preço de cada bairro no treinamento e substituir o nome de cada bairro por esse valor. Depois, essa mesma média foi aplicada no teste e, em caso do surgimento de um bairro novo, ele seria preenchido com a média geral dos bairros.

Experimentou-se usar One-Hot Encoding, transformando cada bairro em uma coluna binária. Entretanto, por haver uma grande quantidade de bairros diferentes, o resultado obtido foi pior do que o método com cálculo da média.

4 Modelo


O modelo de regressão escolhido foi o Random Forest Regressor, pois ele apresentou melhor estabilidade e menor variância do que as alternativas, tendo resultados melhores. A amostra de treinamento foi dividida em 80% para treino e 20% para teste, com 500 árvores de decisão para formar a floresta. Seu desempenho (R^2) foi de aproximadamente 0.84. O fit do modelo foi feito baseado no logaritmo dos preços dos imóveis de treinamento, porque, assim, o score resultante foi levemente melhor do que sem usar o logaritmo.

Antes de usar o modelo de Random Forest, foi usada a Regressão Linear, mas ela causou um desempenho (R^2) menor, de aproximadamente 0.59.


Depois, também foi testado o modelo XGBoost, que gerou resultados piores, por causar overfitting no conjunto de testes.

5 Resultados

Foi calculada a importância relativa de cada variável para o resultado final.



Variável	Importância
Área Útil	64.1%
Vagas	11.3%
Suítes	10.2%
Preço da Localização	8.6%
Área Extra	1.6%
Quartos Simples	1.5%
Score Lazer	1.4%
Vista para o mar	0.5%
Tipo de Imóvel	0.5%
Tipo de Vendedor	0.1%



Nesta imagem, é possível ver que a grande maioria dos imóveis fica bem próximo da reta tracejada, enquanto muitos outros passam diretamente por cima dela. A reta tracejada representa o acerto perfeito do modelo. Também é possível ver alguns imóveis em que o valor previsto foi muito equivocado, o que significa que aquele imóvel em questão é atípico, provavelmente sendo um imóvel de luxo. Isso é embasado pelas métricas de Erro Médio Absoluto (R\$ 116,710.68) e Raiz do Erro Quadrático (R\$ 219,443.79), que estão bem distantes, indicando que o modelo é bom para a maioria dos imóveis e falha nos imóveis mais incomuns.